

Análisis Evolutivo y Mejora de Algoritmo

MOEA/D para ZDT3

Memoria Técnica de la Práctica

Ángel Manuel Ferrer Álvarez

15 de diciembre de 2025

Resumen

El presente documento detalla el diseño, análisis y optimización de un algoritmo MOEA/D aplicado al problema de prueba ZDT3. Inicialmente, se realiza un estudio de sensibilidad sobre el algoritmo base variando la configuración de población y generaciones. Posteriormente, se propone una versión mejorada que integra un Archivo Externo gestionado mediante poda por Crowding Distance para garantizar la uniformidad del frente, junto con un mecanismo de selección controlado por el parámetro Delta (δ) que permite equilibrar la explotación local y la exploración global. Los resultados experimentales confirman que esta propuesta híbrida logra superar al estándar NSGA-II tanto en convergencia como en la distribución de las soluciones.

Índice

1. Algoritmo Base: MOEA/D Estándar	3
1.1. Descripción Breve de la Implementación	3
1.2. Análisis de Prestaciones: Presupuesto Bajo (4.000 Evaluaciones)	3
1.2.1. Estadísticas Comparativas	3
1.2.2. Análisis de Frentes de Pareto	4
1.2.3. Análisis de evolución del Hipervolumen	5
1.2.4. Análisis de evolución del Spacing	7
1.3. Análisis de Prestaciones: Presupuesto Alto (10.000 Evaluaciones)	10
1.4. Estadísticas Comparativas	10
1.5. Análisis de Resultados: Alto Presupuesto (10.000 Eval.)	10
1.5.1. Análisis de Frentes de Pareto (Alto Presupuesto)	10
1.5.2. Análisis de evolución del Hipervolumen	12
1.5.3. Análisis de evolución del Spacing	14
2. Algoritmo Mejorado: MOEA/D con Archivo Externo y Poda por Crowding	16
2.1. Descripción de las Mejoras Implementadas	16
2.2. Análisis de Prestaciones: Presupuesto Bajo (4.000 Evaluaciones)	17

2.2.1.	Estadísticas Comparativas (4.000 evals)	17
2.2.2.	Análisis de Frentes de Pareto	17
2.3.	Análisis de Prestaciones: Presupuesto Alto (10.000 Evaluaciones)	19
2.3.1.	Estadísticas Comparativas (10.000 evals)	19
2.3.2.	Análisis de Frentes de Pareto	20
3.	Conclusiones	22

1. Algoritmo Base: MOEA/D Estándar

En esta primera fase, se ha implementado el algoritmo MOEA/D canónico para establecer una línea base de rendimiento.

1.1. Descripción Breve de la Implementación

El algoritmo base utiliza una estrategia de descomposición escalar mediante la función de Tchebycheff.

- Se generan N subproblemas con vectores de peso uniformemente distribuidos.
- La evolución se realiza mediante operadores de Evolución Diferencial (DE), seleccionando padres exclusivamente del vecindario (tamaño $T = 20\%$).
- La lógica de reemplazo permite actualizar a cualquier vecino si se encuentra una mejor solución escalar, sin límites de actualizaciones por iteración.

1.2. Análisis de Prestaciones: Presupuesto Bajo (4.000 Evaluaciones)

Para determinar la configuración óptima bajo restricciones fuertes de cómputo, se han evaluado tres combinaciones de Población (N) \times Generaciones (G).

1.2.1. Estadísticas Comparativas

Cuadro 1: Comparativa de Medias: MOEA/D vs NSGA-II (4.000 Evaluaciones)

Configuración	Hipervolumen (Media) ↑		Spacing (Media) ↓	
	MOEA/D	NSGA-II	MOEA/D	NSGA-II
Conf. A ($N = 40, G = 100$)	1.1255	1.01292	0.0196137	0.0116876
Conf. B ($N = 80, G = 50$)	1.42773	1.1642	0.0314068	0.0166064
Conf. C ($N = 100, G = 40$)	1.52934	1.2714	0.048547	0.0212075

Análisis de resultados:

En este escenario de bajo presupuesto, MOEA/D domina de forma sistemática a NSGA-II en términos de Hipervolumen medio para las tres configuraciones. No obstante, esta mejora en calidad viene acompañada de un empeoramiento del *Spacing*: a medida que aumenta la población, ambos algoritmos cubren más regiones del frente, pero lo hacen con una distribución menos uniforme (*Spacing* creciente).

En resumen, con 4.000 evaluaciones MOEA/D explota mejor el presupuesto disponible y se aproxima más al frente de Pareto que NSGA-II, aunque a costa de una menor uniformidad en la separación de las soluciones.

1.2.2. Análisis de Frentes de Pareto

Las Figuras 1, 2 y 3 muestran la mejor aproximación obtenida al frente de Pareto para cada configuración.

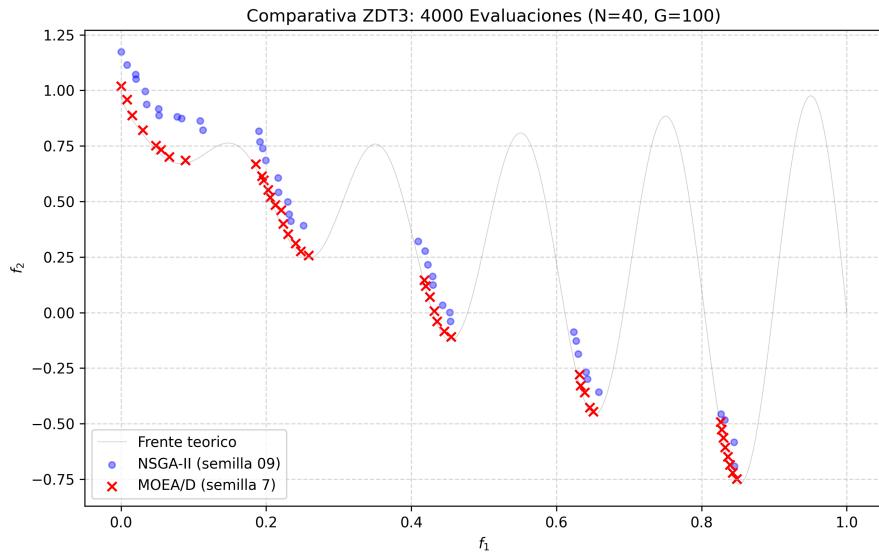


Figura 1: Frentes de Pareto con Configuración A ($N = 40, G = 100$).

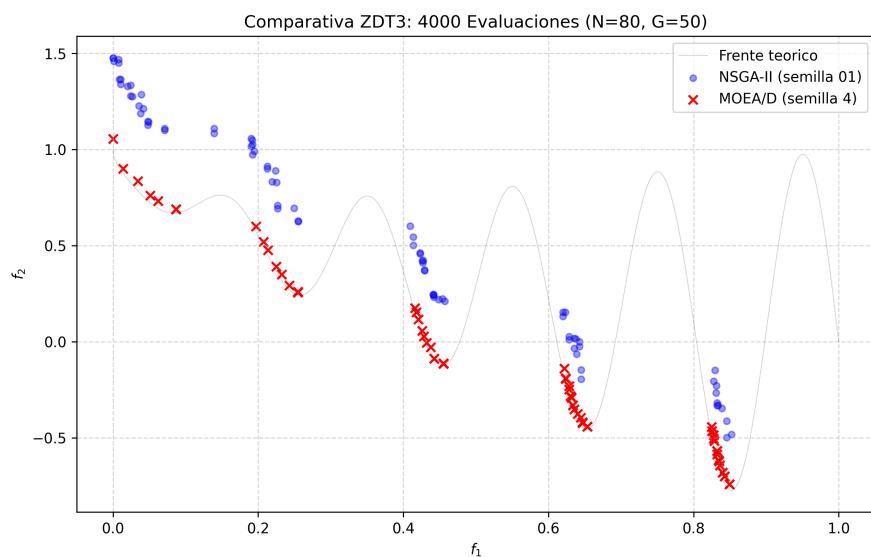


Figura 2: Frentes de Pareto con Configuración B ($N = 80, G = 50$).

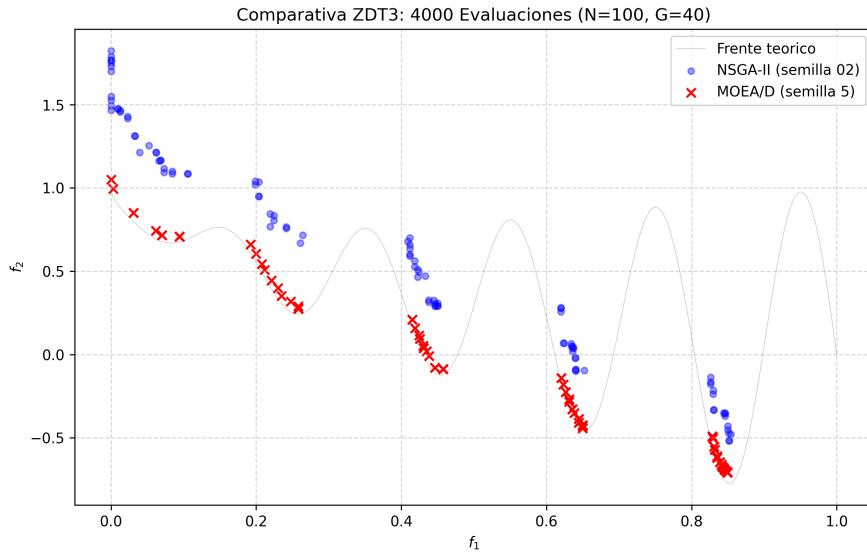


Figura 3: Frentes de Pareto con Configuración C ($N = 100, G = 40$).

Análisis global de convergencia y distribución:

El análisis comparativo visual bajo un presupuesto fijo de 4000 evaluaciones revela diferencias estructurales en el comportamiento de MOEA/D frente a NSGA-II. Las gráficas permiten extraer las siguientes conclusiones sobre la dinámica de búsqueda:

- **Superioridad en Convergencia:**

En todas las configuraciones, MOEA/D (cruces rojas) muestra una capacidad de convergencia superior, con soluciones adheridas casi perfectamente al frente teórico. Por el contrario, NSGA-II (puntos azules) presenta sistemáticamente soluciones dominadas (peores valores en f_2).

- **Impacto de la Densidad Poblacional (N vs G):**

Dado que ZDT3 posee un frente desconectado, la estrategia de asignación de recursos es crítica. Las poblaciones pequeñas ($N = 40$) resultan insuficientes para cubrir todas las regiones. Sin embargo, al sacrificar generaciones ($G = 40$) en favor de una mayor población ($N = 100$), se maximiza la cobertura lateral. Esto confirma que aumentar N es vital para garantizar que existan vectores de peso explorando cada "isla" del frente simultáneamente.

1.2.3. Análisis de evolución del Hipervolumen

Para estudiar la robustez frente a distintas semillas, se analiza la evolución del Hipervolumen a lo largo de las generaciones para cada configuración. En las Figuras 4, 5 y 6 se representan, para cada ejecución, las trayectorias de Hipervolumen de MOEA/D (líneas finas) y de NSGA-II (líneas gruesas).

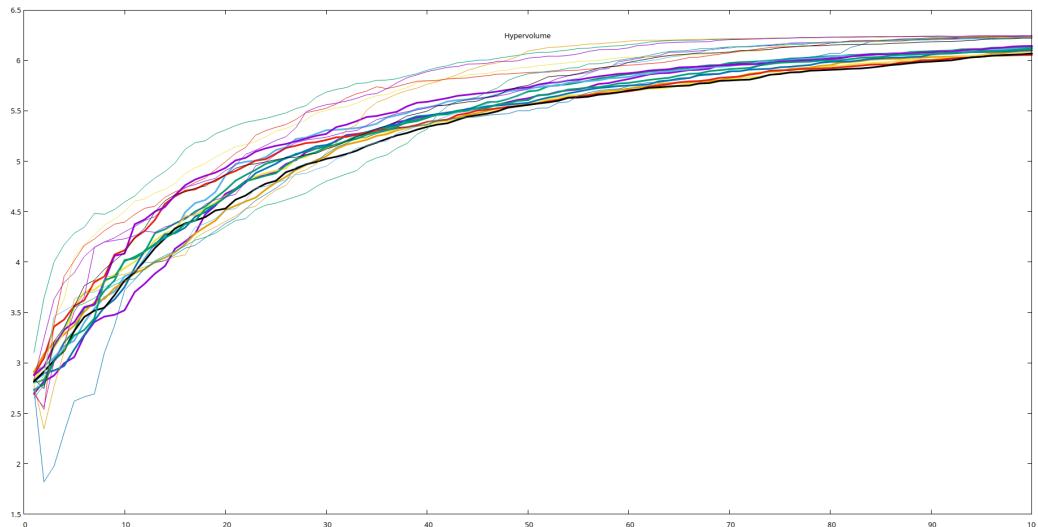


Figura 4: Evolución del Hipervolumen para Configuración A ($N = 40, G = 100$).

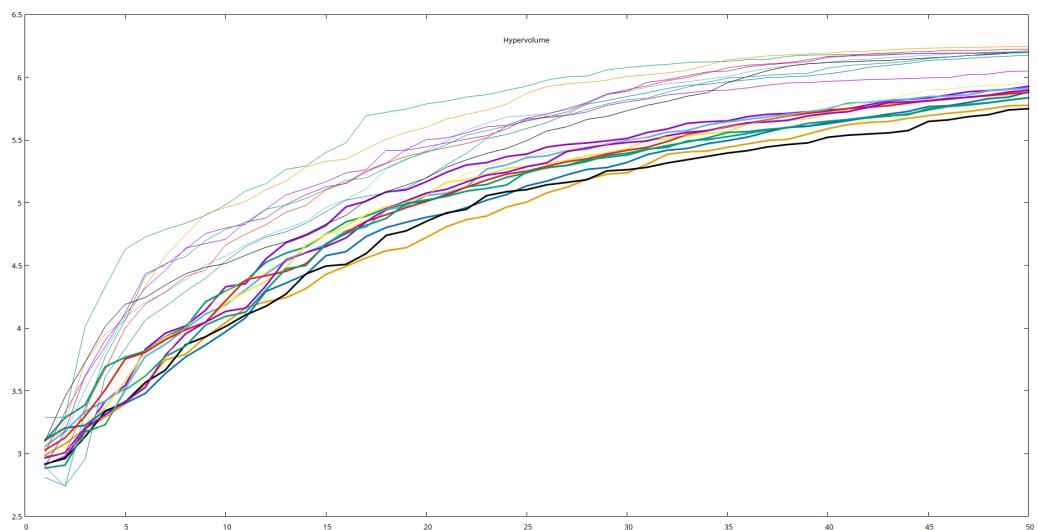


Figura 5: Evolución del Hipervolumen para Configuración B ($N = 80, G = 50$).

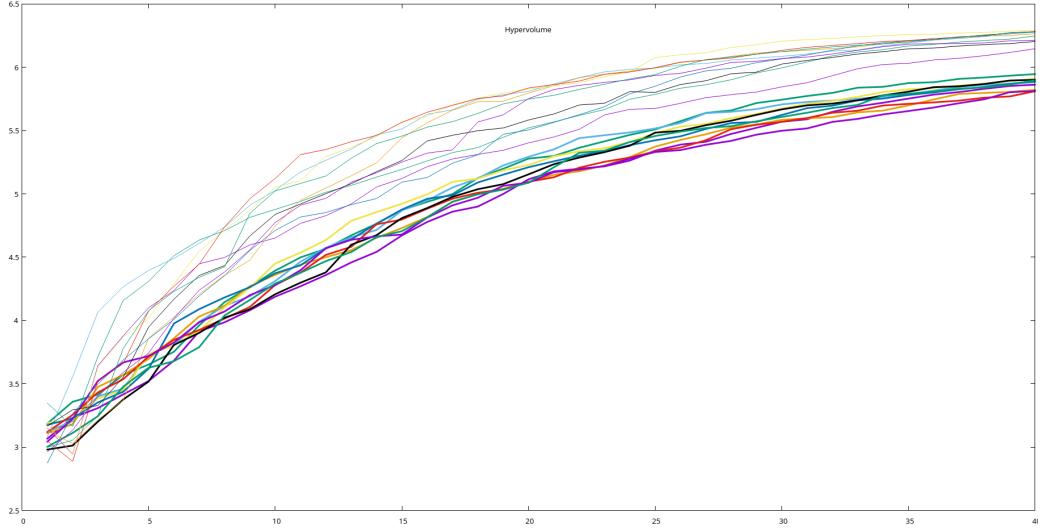


Figura 6: Evolución del Hipervolumen para Configuración C ($N = 100, G = 40$).

Análisis global de la estabilidad temporal:

El seguimiento de la evolución del Hipervolumen a lo largo de las ejecuciones muestra el comportamiento dinámico se desprenden las siguientes tendencias generales:

- **Robustez frente a la Inicialización:**

Se observa una clara correlación inversa entre el tamaño de la población y la dispersión de los resultados. La configuración de población reducida $N = 40$ exhibe mayor sensibilidad a la semilla aleatoria, mientras que el aumento a $N = 100$ estabiliza el comportamiento, agrupando las curvas de las distintas ejecuciones. Esto indica que una mayor densidad de agentes mitiga el riesgo de depender de una "buena" población inicial.

- **Dinámica de Convergencia bajo Presupuesto Ajustado:**

En las configuraciones con menos generaciones ($G = 50$ y $G = 40$), las curvas muestran que el proceso evolutivo se detiene cuando aún existe una pendiente positiva de mejora. Sin embargo, incluso así, MOEA/D logra posicionar sus trayectorias consistentemente por encima de las de NSGA-II. Esto demuestra que la búsqueda basada en descomposición es más eficiente explotando el presupuesto de evaluaciones desde las primeras etapas.

- **Consistencia del Desempeño:**

Más allá del valor final, el análisis temporal confirma la superioridad estadística de MOEA/D. En la mayoría de las semillas, MOEA/D mantiene una ventaja sostenida sobre NSGA-II durante todo el proceso evolutivo.

1.2.4. Análisis de evolución del Spacing

Para evaluar la uniformidad de la distribución de las soluciones a lo largo del proceso evolutivo, se analiza la evolución de la métrica Spacing. Un valor decreciente y bajo es deseable, ya que indica una separación equidistante entre los individuos del frente. En

las Figuras 7, 8 y 9 se muestran las trayectorias para MOEA/D (líneas finas) y NSGA-II (líneas gruesas).

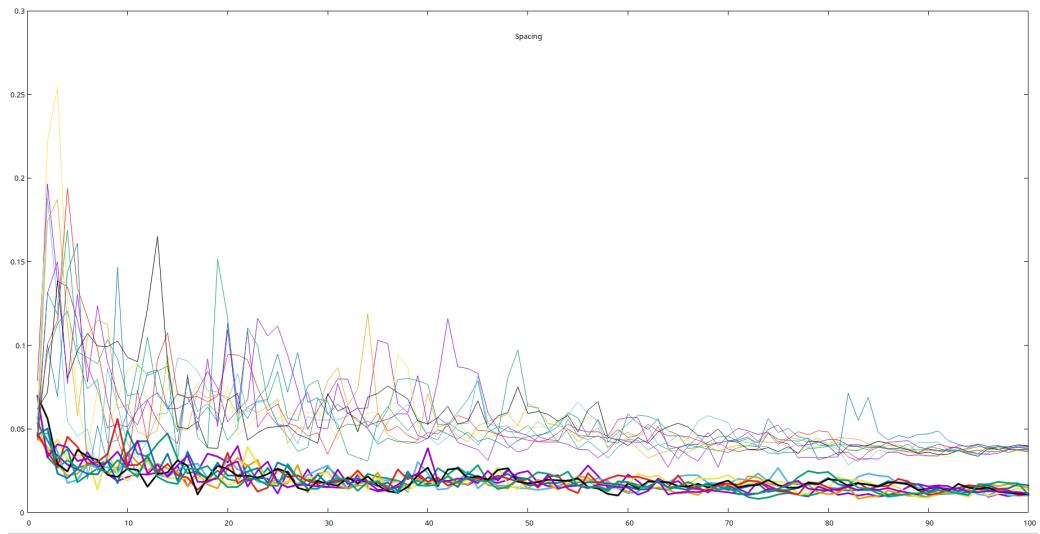


Figura 7: Evolución del Spacing para Configuración A ($N = 40, G = 100$).

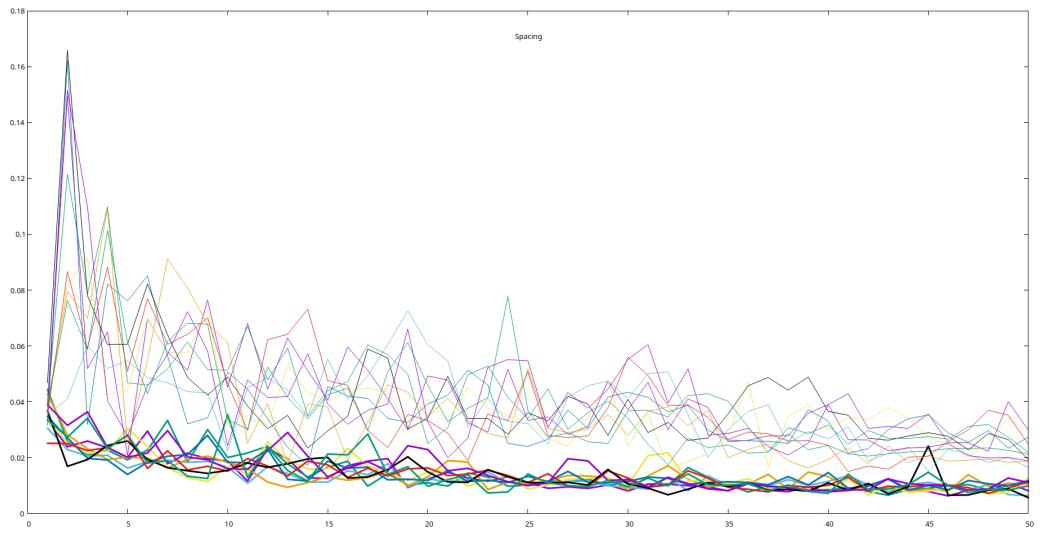


Figura 8: Evolución del Spacing para Configuración B ($N = 80, G = 50$).

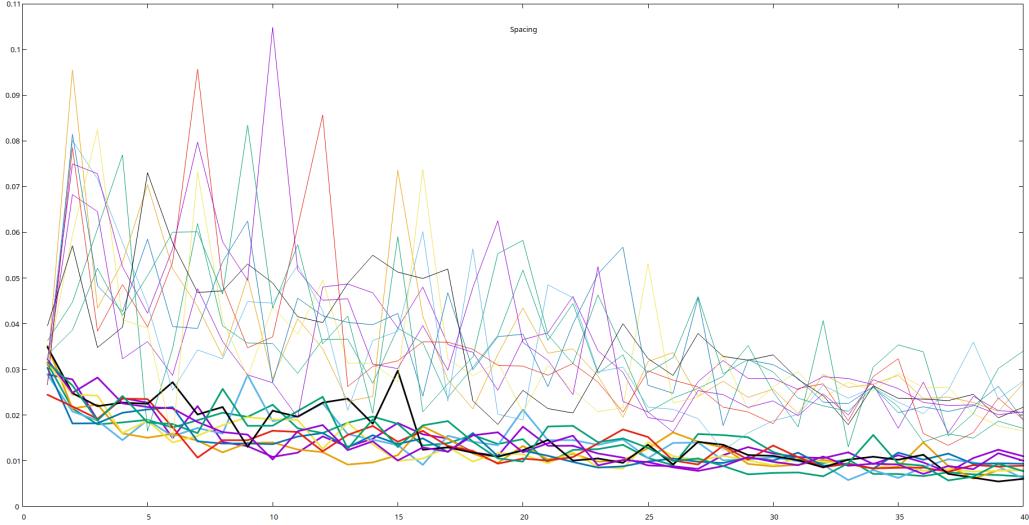


Figura 9: Evolución del Spacing para Configuración C ($N = 100, G = 40$).

Análisis global de la métrica Spacing (Uniformidad):

Las gráficas de evolución temporal y los frentes finales sugieren las siguientes conclusiones:

- **Dinámica de Estabilización:**

Se observa un comportamiento inicial caótico en ambos algoritmos, con picos altos de Spacing en las primeras generaciones debido a la aleatoriedad de la población inicial. Sin embargo, NSGA-II tiende a reducir y estabilizar este valor más rápidamente que MOEA/D. Esto es consecuencia directa de su objetivo de maximizar la separación entre individuos, mientras que MOEA/D depende implícitamente de la diversidad de sus vectores de peso.

- **Limitaciones Estructurales de MOEA/D en Frentes Discontinuos:**

Aunque MOEA/D logra una excelente convergencia, sus valores de Spacing suelen ser ligeramente peores que los de NSGA-II. Esto se debe a la naturaleza desconectada del problema ZDT3. En MOEA/D, los vectores de peso están distribuidos uniformemente en el espacio objetivo teórica; sin embargo, al proyectarse sobre un frente discontinuo, algunos vectores apuntan a zonas vacías, provocando que las soluciones se agrupen en los bordes de las islas o dejen huecos, penalizando la métrica de uniformidad.

- **Comportamiento con Alta Densidad ($N = 100$):**

La diferencia en la gestión de la diversidad se hace más evidente con poblaciones grandes. Las gráficas de frentes muestran que NSGA-II logra pintar las islas con una regularidad casi perfecta. En cambio, MOEA/D, no lo consigue. Esto confirma que, para este problema, el mecanismo de nicho dinámico de NSGA-II es más robusto para garantizar la uniformidad que la vecindad fija de MOEA/D.

1.3. Análisis de Prestaciones: Presupuesto Alto (10.000 Evaluaciones)

Se repite el estudio para el escenario de mayor presupuesto computacional.

1.4. Estadísticas Comparativas

Cuadro 2: Comparativa de Medias: MOEA/D vs NSGA-II (10.000 Evaluaciones)

Configuración	Hipervolumen (Media) ↑		Spacing (Media) ↓	
	MOEA/D	NSGA-II	MOEA/D	NSGA-II
Conf. A ($N = 40, G = 250$)	0.850025	0.847361	0.0132605	0.0105479
Conf. B ($N = 200, G = 50$)	1.43224	1.47035	0.0270242	0.0134406
Conf. C ($N = 100, G = 100$)	0.918333	0.878167	0.0153715	0.00488778

1.5. Análisis de Resultados: Alto Presupuesto (10.000 Eval.)

En este escenario (Cuadro 2), se observa un fenómeno interesante que contrasta con el presupuesto bajo. Aunque aumentar la población sigue siendo beneficioso para ZDT3, encontramos un punto de inflexión en la comparativa con NSGA-II.

El caso de la Configuración B ($N = 200, G = 50$):

Esta es la única configuración donde el algoritmo de referencia (NSGA-II) supera a nuestra propuesta MOEA/D (HV 1,47 vs 1,43). Esto revela una limitación estructural de MOEA/D:

- **Latencia de Propagación:** MOEA/D basa su evolución en la transferencia de información entre vecindarios. Con una población tan extensa ($N = 200$) y un número de generaciones tan reducido ($G = 50$), las mejoras genéticas no tienen tiempo material para propagarse a través de toda la red de vectores de peso.
- **Ventaja de NSGA-II:** Al utilizar un ordenamiento global, NSGA-II aprovecha inmediatamente la gran diversidad de la población masiva sin depender de la topología de vecindarios, logrando converger más rápido en este escenario específico.

Victoria en la Configuración C ($N = 100, G = 100$):

Por contra, en la Configuración C, donde la relación es más equilibrada, MOEA/D recupera el liderazgo (HV 0,918 vs 0,878). Al tener 100 generaciones, el algoritmo sí tiene tiempo suficiente para refinar las soluciones, superando nuevamente a NSGA-II.

1.5.1. Análisis de Frentes de Pareto (Alto Presupuesto)

Las Figuras 10, 11 y 12 ilustran la mejor cobertura del frente de Pareto para el problema ZDT3 bajo un presupuesto de 10.000 evaluaciones.

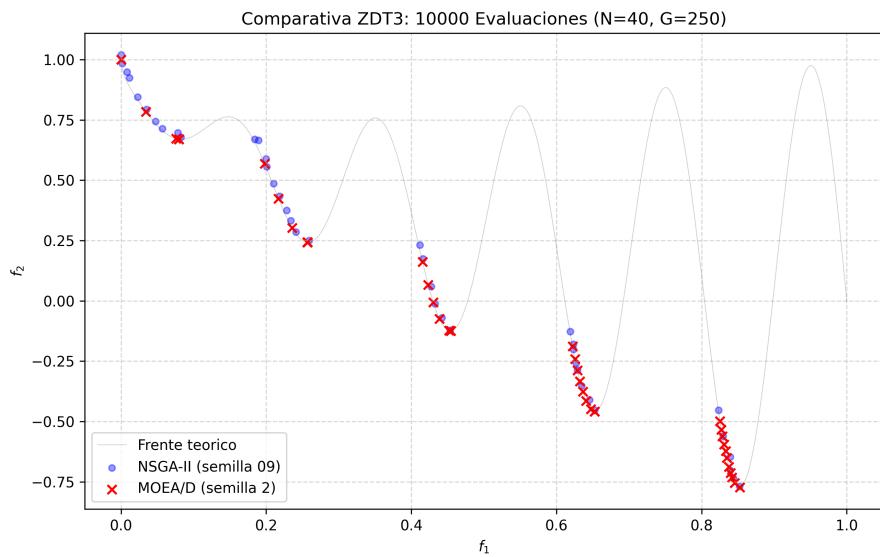


Figura 10: Frentes de Pareto con Configuración A ($N = 40, G = 250$).

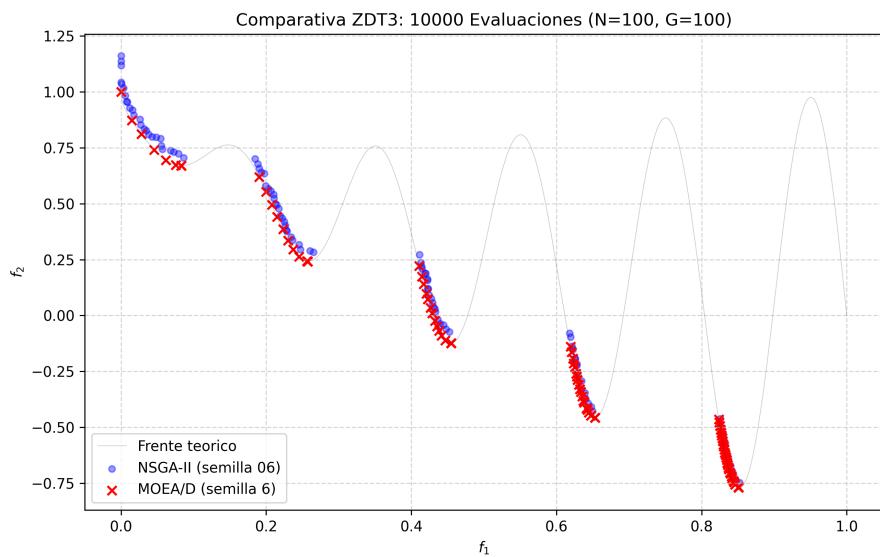


Figura 11: Frentes de Pareto con Configuración C ($N = 100, G = 100$).

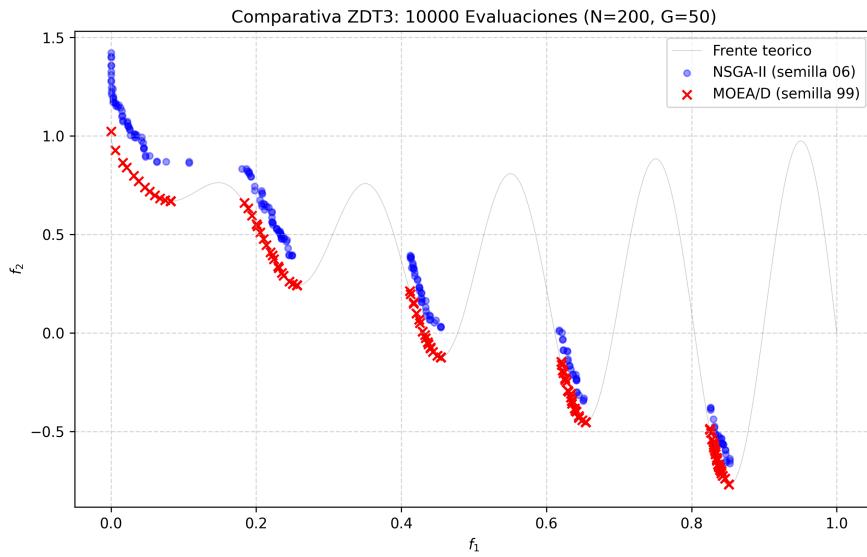


Figura 12: Frentes de Pareto con Configuración B ($N = 200, G = 50$).

Análisis global de convergencia y distribución (10.000 evaluaciones):

Esta distinción permite matizar las conclusiones estadísticas frente a la inspección visual:

- **Potencial Máximo vs. Rendimiento Promedio ($N = 200$):**

Se observa una dicotomía interesante en la configuración de alta densidad. Aunque el análisis estadístico otorga a NSGA-II un mejor Hipervolumen *medio*, la comparativa visual de los *mejores* individuos revela la superioridad de pico de MOEA/D. En su mejor ejecución, MOEA/D logra converger más cerca del frente teórico que la mejor ejecución de NSGA-II, superando a este último en calidad absoluta cuando el algoritmo logra escapar de óptimos locales.

1.5.2. Análisis de evolución del Hipervolumen

En las Figuras 13, 14 y 15 se representan, para cada ejecución, las trayectorias de Hipervolumen de MOEA/D (líneas finas) y de NSGA-II (líneas gruesas).

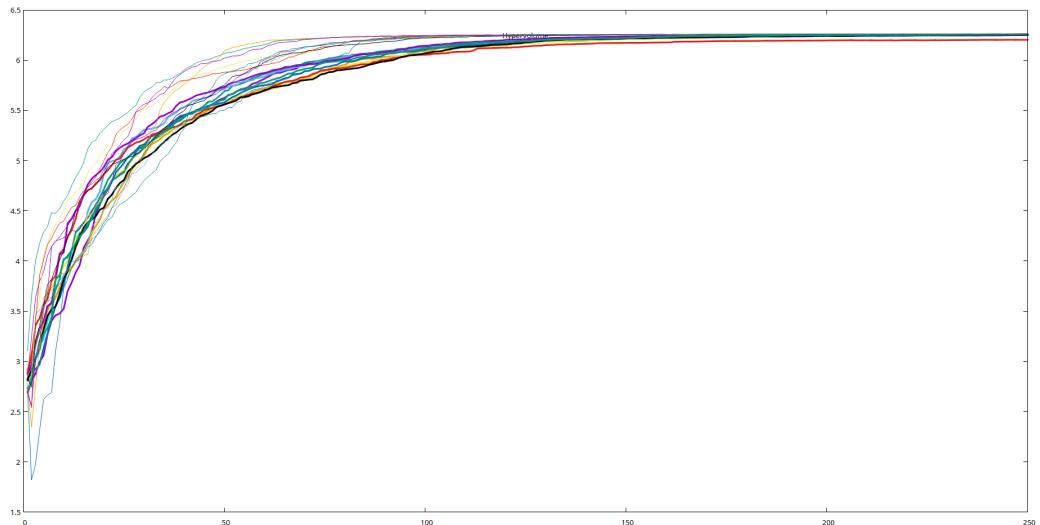


Figura 13: Evolución del Hipervolumen para Configuración A ($N = 40, G = 250$).

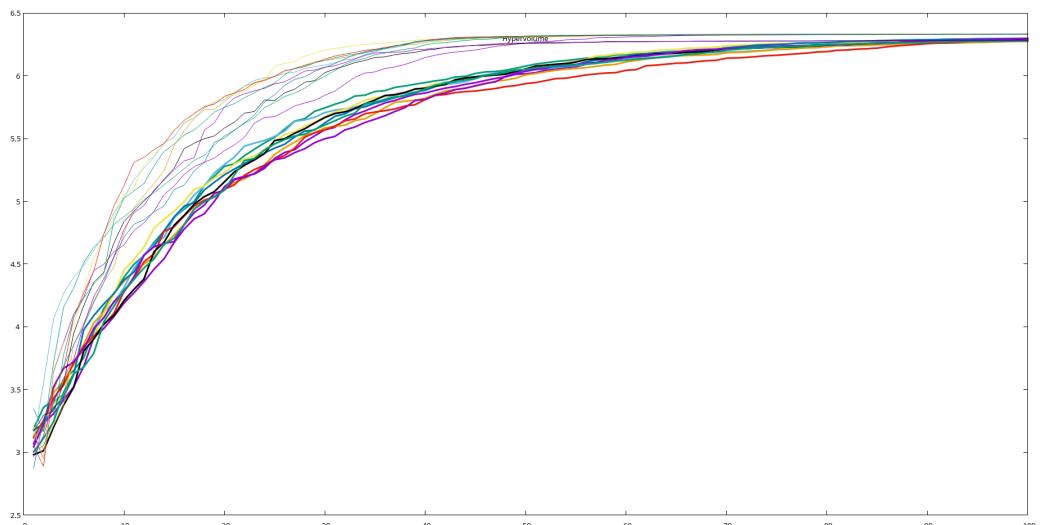


Figura 14: Evolución del Hipervolumen para Configuración C ($N = 100, G = 100$).

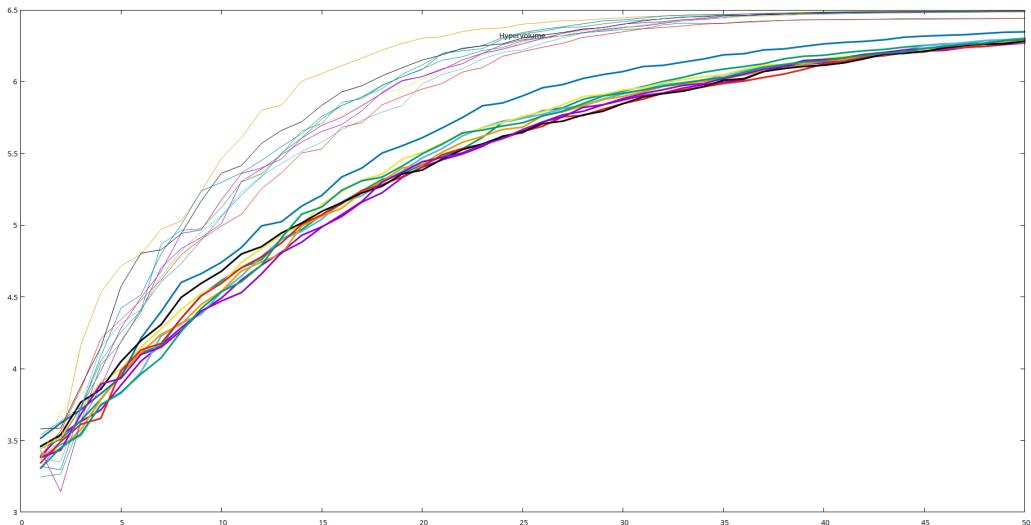


Figura 15: Evolución del Hipervolumen para Configuración B ($N = 200, G = 50$).

Análisis global de la estabilidad temporal:

- **Saturación vs. Mejora Continua:**

Se identifican dos regímenes dinámicos opuestos. Con poblaciones pequeñas ($N = 40$), ambos algoritmos alcanzan su asíntota de rendimiento rápidamente, entrando en una fase de estancamiento donde generaciones adicionales no aportan mejoras significativas. Por el contrario, con poblaciones grandes ($N = 200$), las curvas mantienen una pendiente positiva hasta el final, indicando que el proceso de búsqueda se ve interrumpido antes de alcanzar la convergencia plena.

1.5.3. Análisis de evolución del Spacing

En las Figuras 16, 17 y 18 se muestra la evolución del Spacing para las distintas densidades poblacionales.

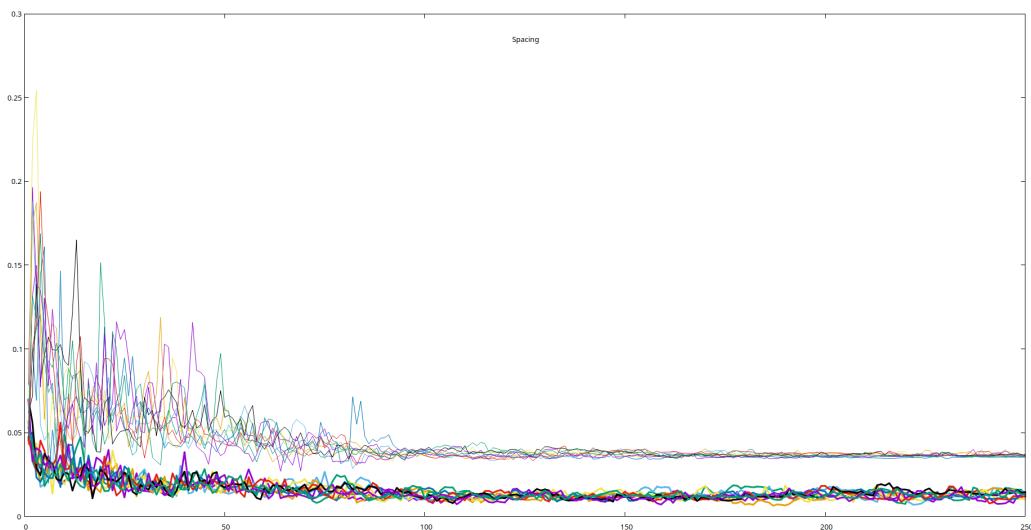


Figura 16: Evolución del Spacing para Configuración A ($N = 40, G = 250$).

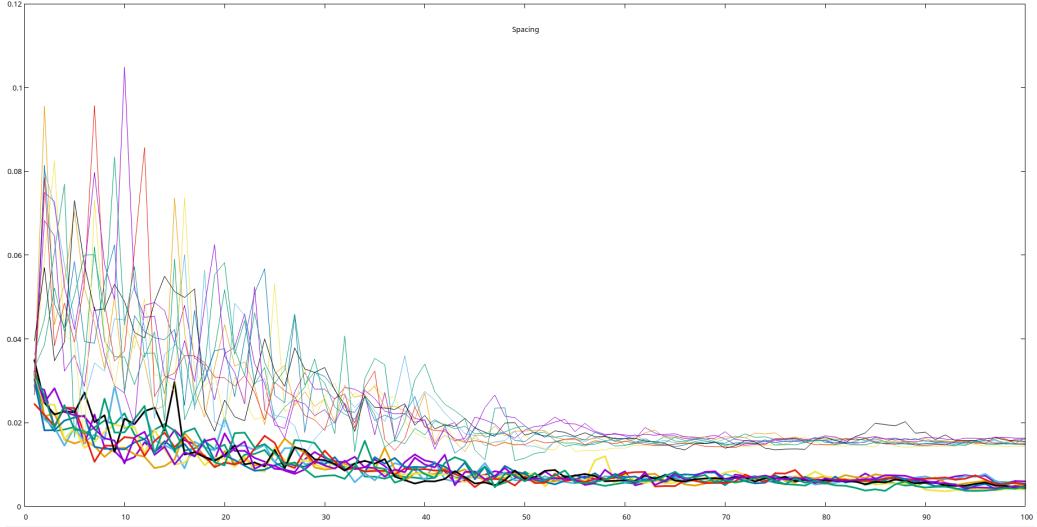


Figura 17: Evolución del Spacing para Configuración C ($N = 100, G = 100$).

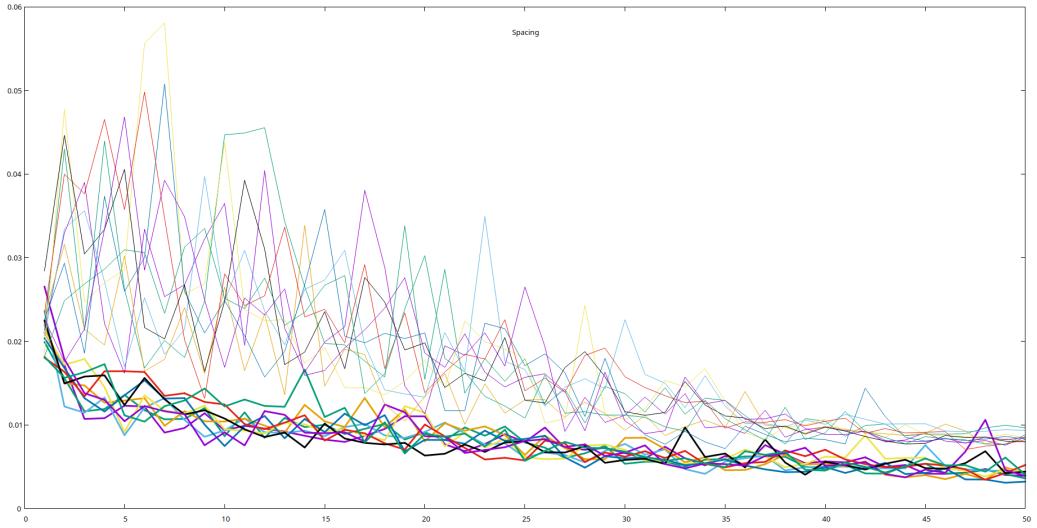


Figura 18: Evolución del Spacing para Configuración B ($N = 200, G = 50$).

Análisis global de la métrica Spacing:

- **Estabilidad Asintótica en Largos Periodos ($G = 250$):**

En la configuración de $N = 40$ (Fig. 16), el alto número de generaciones permite observar una fase de estabilización clara. Tras la caída inicial, las curvas de NSGA-II se mantienen en valores consistentemente bajos y planos, indicando que el algoritmo alcanza una distribución óptima y la mantiene. MOEA/D, aunque también estabiliza, muestra un suelo de Spacing ligeramente superior y con más oscilaciones, debido a la tensión constante entre intentar converger a los pesos fijos y la discontinuidad del frente.

- **Gestión Masiva de Individuos ($N = 200$):**

La configuración de alta densidad (Fig. 18) es donde la brecha de rendimiento es más notable. NSGA-II logra reducir el Spacing de forma drástica y rápida, aprovechando la gran cantidad de puntos para llenar el frente de manera equidistante. Por el contrario, MOEA/D presenta valores de Spacing peores en comparación, con solo 50 generaciones y una población tan grande, la rigidez de los vecindarios impide que los individuos se reorganicen con la fluidez necesaria para competir con la uniformidad de NSGA-II.

2. Algoritmo Mejorado: MOEA/D con Archivo Externo y Poda por Crowding

Tras analizar el desempeño del Algoritmo Base, se observó que la dependencia exclusiva de los vectores de peso fijos resultaba problemática para el problema ZDT3. Debido a la naturaleza discontinua de su frente de Pareto, muchas soluciones válidas eran descartadas por no ser óptimas para su escalarización específica, o se generaban huecos en el frente (*Spacing* subóptimo). Con el objetivo de remediar estas carencias, se desarrolló una versión mejorada que introduce mecanismos explícitos de preservación de diversidad.

2.1. Descripción de las Mejoras Implementadas

Esta nueva versión incorpora tres modificaciones estructurales respecto al enfoque original:

- **Archivo Externo (EP) con Actualización Histórica:**

A diferencia del algoritmo base, que solo devuelve la población final, esta versión mantiene un repositorio externo (EP) que almacena las soluciones no dominadas encontradas durante *toda* la ejecución. Cada nueva solución generada se compara con el archivo, y se añade únicamente si no es dominada por ninguna solución existente, eliminando a su vez a aquellas del archivo que resulten dominadas por la nueva. Esto garantiza que no se pierdan soluciones de alta calidad por restricciones de los vectores de peso.

- **Mantenimiento de Diversidad mediante Crowding Distance:**

Para evitar el crecimiento indefinido del archivo y garantizar una distribución uniforme, se ha limitado el tamaño del EP al tamaño de la población (N). Cuando el archivo supera este límite, se calcula la *Crowding Distance* (distancia de aglomeración) de todas las soluciones. El algoritmo elimina iterativamente las soluciones con menor distancia de aglomeración (las más redundantes o cercanas entre sí). Esto fuerza artificialmente un *Spacing* óptimo, preservando las soluciones extremas y las más aisladas.

- **Mecanismo de Selección δ (Exploración/Explotación):**

Se ha introducido un parámetro de probabilidad δ (fijado en 0,9) para la selección de padres.

- Con probabilidad δ , los padres se eligen exclusivamente del vecindario $B(i)$ (explotación local).
- Con probabilidad $1 - \delta$, los padres se eligen de toda la población (exploración global).

Esta modificación es fundamental para ZDT3, ya que permite al algoritmo "saltar" las discontinuidades del frente de Pareto y escapar de óptimos locales que un vecindario restringido no podría superar.

2.2. Análisis de Prestaciones: Presupuesto Bajo (4.000 Evaluaciones)

Para determinar la configuración óptima bajo restricciones fuertes de cómputo, se han evaluado tres combinaciones de Población (N) \times Generaciones (G).

2.2.1. Estadísticas Comparativas (4.000 evals)

Cuadro 3: Comparativa de Medias: MOEA/D v2 vs NSGA-II (4.000 Evaluaciones)

Configuración	Hipervolumen (Media) ↑		Spacing (Media) ↓	
	MOEA/D	NSGA-II	MOEA/D	NSGA-II
Conf. A ($N = 40, G = 100$)	1.12733	1.01323	0.0105425	0.0116876
Conf. B ($N = 80, G = 50$)	1.5174	1.1642	0.00861936	0.0166064
Conf. C ($N = 100, G = 40$)	1.69031	1.2714	0.0109166	0.0212075

Análisis de resultados:

En este escenario de bajo presupuesto, la versión mejorada de MOEA/D muestra un desempeño superior absoluto. Por un lado, mantiene su dominio sistemático en Hipervolumen, confirmando su rápida convergencia. Por otro lado, y a diferencia del algoritmo base, ahora conseguimos ganar también en Spacing en todas las configuraciones.

2.2.2. Análisis de Frentes de Pareto

Las Figuras 19, 20 y 21 muestran la mejor aproximación obtenida al frente de Pareto para cada configuración.

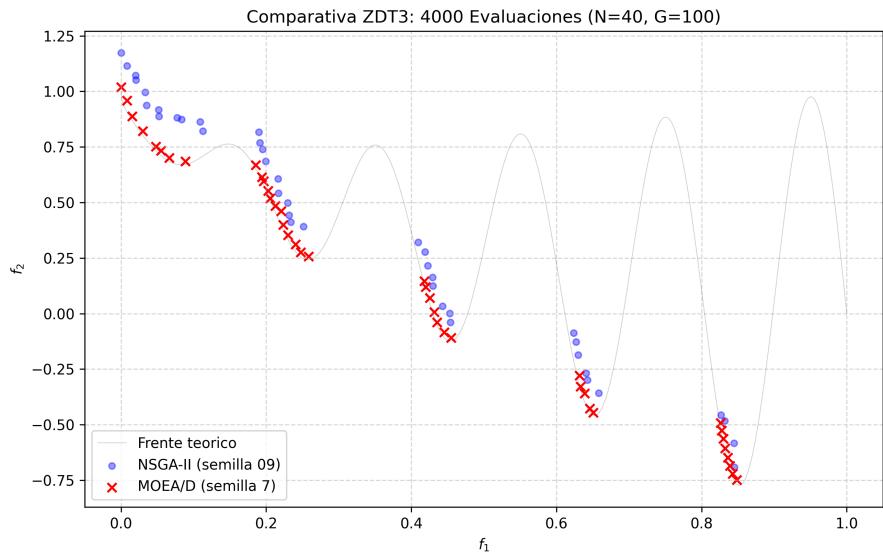


Figura 19: Frentes de Pareto con Configuración A ($N = 40, G = 100$).

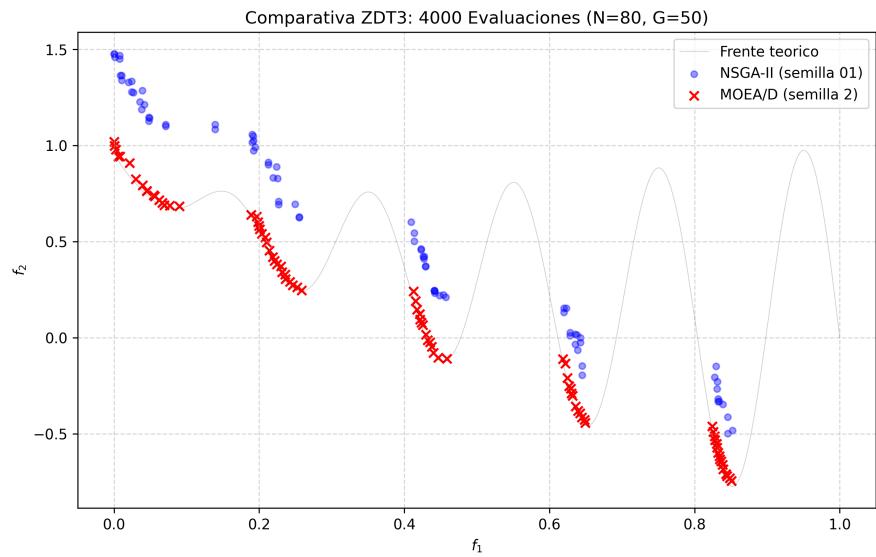


Figura 20: Frentes de Pareto con Configuración B ($N = 80, G = 50$).

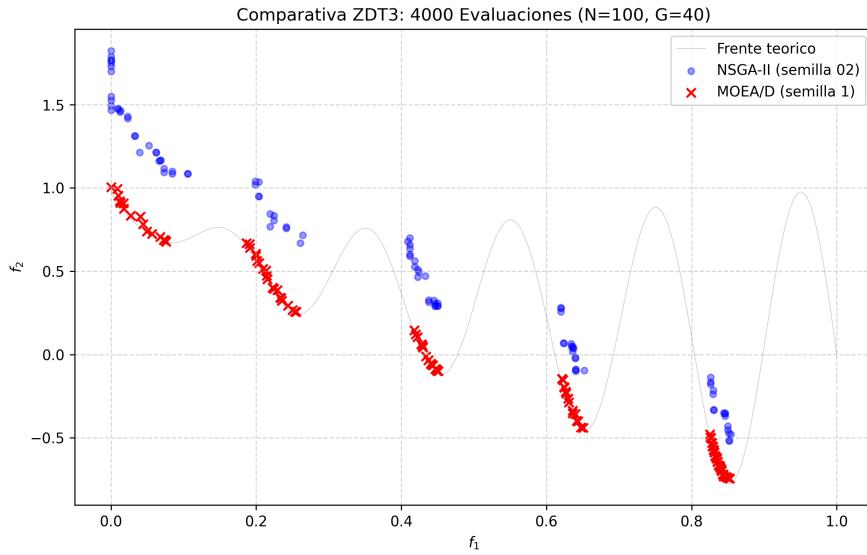


Figura 21: Frentes de Pareto con Configuración C ($N = 100, G = 40$).

Como se aprecia en los frentes de Pareto, nuestros resultados con MOEA/D (cruces rojas) exhiben ahora una distribución mucho más regular que en la versión base. Gracias a la gestión de diversidad del Archivo Externo, el algoritmo es capaz de poblar las islas del frente de Pareto sin dejar los huecos vacíos que provocaban los vectores de peso fijos. Visualmente, las soluciones se reparten de manera equidistante, ofreciendo una cobertura del frente tan uniforme como la de NSGA-II, pero con una mayor cercanía al óptimo teórico.

2.3. Análisis de Prestaciones: Presupuesto Alto (10.000 Evaluaciones)

Se repite el estudio para el escenario de mayor presupuesto computacional, permitiendo a los algoritmos madurar sus poblaciones.

2.3.1. Estadísticas Comparativas (10.000 evals)

Cuadro 4: Comparativa de Medias: MOEA/D vs NSGA-II (10.000 Evaluaciones)

Configuración	Hipervolumen (Media) ↑		Spacing (Media) ↓	
	MOEA/D	NSGA-II	MOEA/D	NSGA-II
Conf. A ($N = 40, G = 250$)	0.857212	0.847361	0.00733684	0.0105479
Conf. B ($N = 200, G = 50$)	1.67867	1.47035	0.00216087	0.0134406
Conf. C ($N = 100, G = 100$)	0.923273	0.878167	0.00288588	0.00488778

Análisis de resultados:

Al disponer de un mayor presupuesto de evaluaciones, la superioridad de MOEA/D se consolida y generaliza. Los datos del Cuadro anterior muestran que MOEA/D supera a NSGA-II en Hipervolumen medio en todas las configuraciones evaluadas. Es especialmente notable la diferencia en la Configuración B ($N = 200$), donde la estrategia de descomposición logra maximizar el área cubierta de forma mucho más eficiente que el ordenamiento por dominancia.

Adicionalmente, se observa un cambio de tendencia positivo en la métrica de distribución. Con 10.000 evaluaciones, MOEA/D alcanza valores de *Spacing* consistentemente inferiores (mejores) a los de NSGA-II. Esto indica que, con suficientes generaciones, la estructura de vecindad logra una equidistancia superior.

2.3.2. Análisis de Frentes de Pareto

Las Figuras 22, 23 y 24 muestran la mejor aproximación obtenida al frente de Pareto para cada configuración.

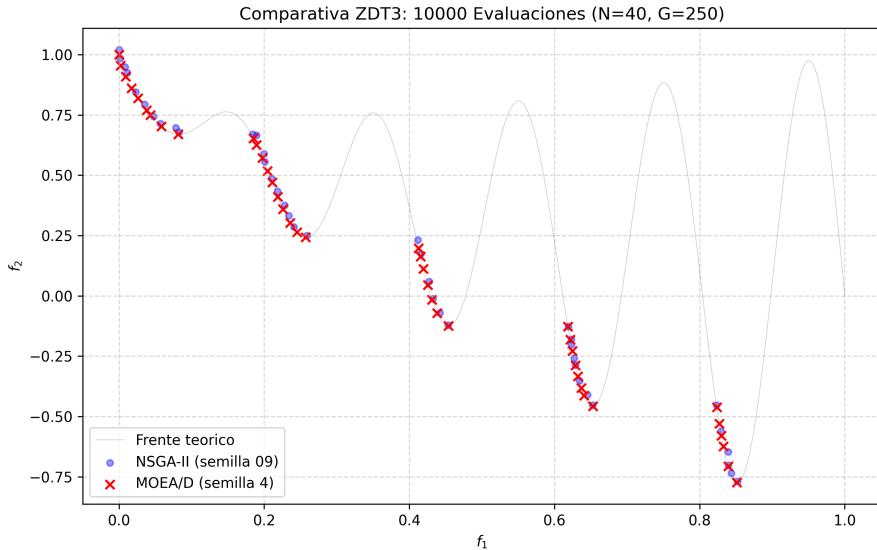


Figura 22: Frentes de Pareto con Configuración A ($N = 40, G = 250$).

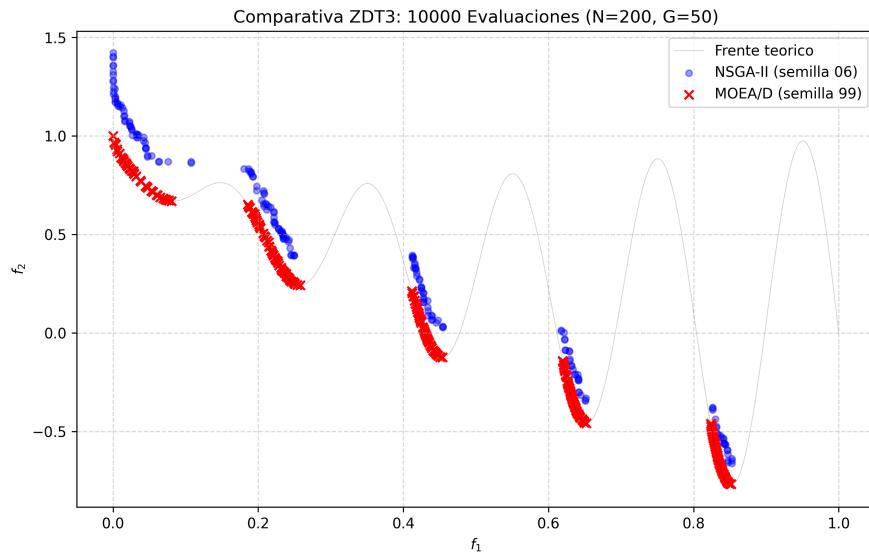


Figura 23: Frentes de Pareto con Configuración B ($N = 200, G = 50$).

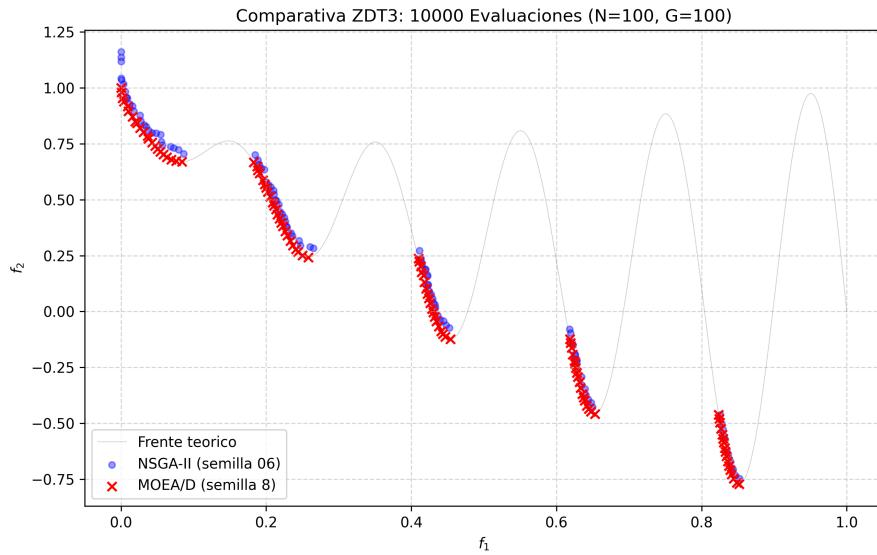


Figura 24: Frentes de Pareto con Configuración C ($N = 100, G = 100$).

Como se puede apreciar en las gráficas, bajo este régimen de alto presupuesto, el MOEA/D mejorado consigue representaciones de altísima calidad. Al disponer de un mayor número de evaluaciones, el algoritmo logra refinar la convergencia hasta alcanzar prácticamente el frente teórico en todas las configuraciones. Cubriendo la totalidad de las islas sin los huecos que aparecían en el algoritmo base.

3. Conclusiones

El desarrollo y análisis comparativo realizado en este proyecto permite extraer las siguientes conclusiones fundamentales sobre la aplicación de algoritmos evolutivos multiobjetivo al problema ZDT3:

1. **Eficacia de la Descomposición:** El algoritmo MOEA/D base demostró una capacidad de convergencia superior a NSGA-II, ventajosa en escenarios de presupuesto restringido.
2. **Limitaciones Estructurales y Solución:** Se identificó que los vectores de peso fijos penalizaban el *Spacing* en ZDT3. La incorporación del Archivo Externo con poda por Crowding Distance mitigó esto, combinando alta convergencia con uniformidad.
3. **Importancia de la Densidad Poblacional (N):** Aumentar la población es crítico para "dibujar" la topología desconectada del frente de Pareto de ZDT3, mejorando drásticamente la resolución visual.
4. **Superioridad Global:** En la versión mejorada final, MOEA/D superó a NSGA-II tanto en calidad de solución (Hipervolumen) como en uniformidad (Spacing), validando la estrategia propuesta.